Programowanie Rozproszone
Mateusz Bednarski
117194 grupa L3

Approximate string search

Wstęp

Zadanie polegało na implementacji algorytmu przybliżonego porównywania stringów, mogącego służyć np. do sprawdzania pisowni.

Słownik

Użyty słownik pochodzi ze strony sjp.pl i zawiera 2 721 111 polskich słów.

Algorytm

Do oceny podobieństwa ciągów została wykorzystana odległość Levenshteina. W skrócie jest to minimalna liczba operacji elementarnych (wstawienie, usunięcie, zamiana pojedynczego znaku) za pomocą których można przekształcić jeden ciąg w drugi. Algorytm iteruje po słowniku i oblicza odległość każdego słowa, po czym wybiera te z minimalną. Złożoność wynosi $O(m^2n)$ gdzie m to długość słowa a n to wielkość słownika.

Implementacja rozproszona

Algorytm zrównoleglenia jest następujący:

Master jest procesem o id = 0, pozostałe są slave.

Master dzieli słownik na n-1 części gdzie n jest liczbą procesów. Każdy slave dostaje część słownika, offset jego części w słowniku głównym oraz słowo do wyszukania (wiadomość REQUEST). Slave wykonuje algorytm sekwencyjny, po czym odsyła wynik do mastera (wiadomość RESPONSE). Master czeka na odpowiedź od wszystkich slave, po czym z otrzymanych wyników wybiera najlepszy.

Struktura wiadomości REQUEST:
Offset : int – offset pierwszego słowa we fragmencie słownika względem całego słownika
Term: string – słowo do wyszukania
Dictionary: list of string - fragment słownika w który dany proces ma przeszukiwać.

Struktura wiadomości RESPONSE
Word : string – znalezione słowo
Index : int – indeks znalezionego słowa
Distance : odległość znalezionego słowa od zadanego

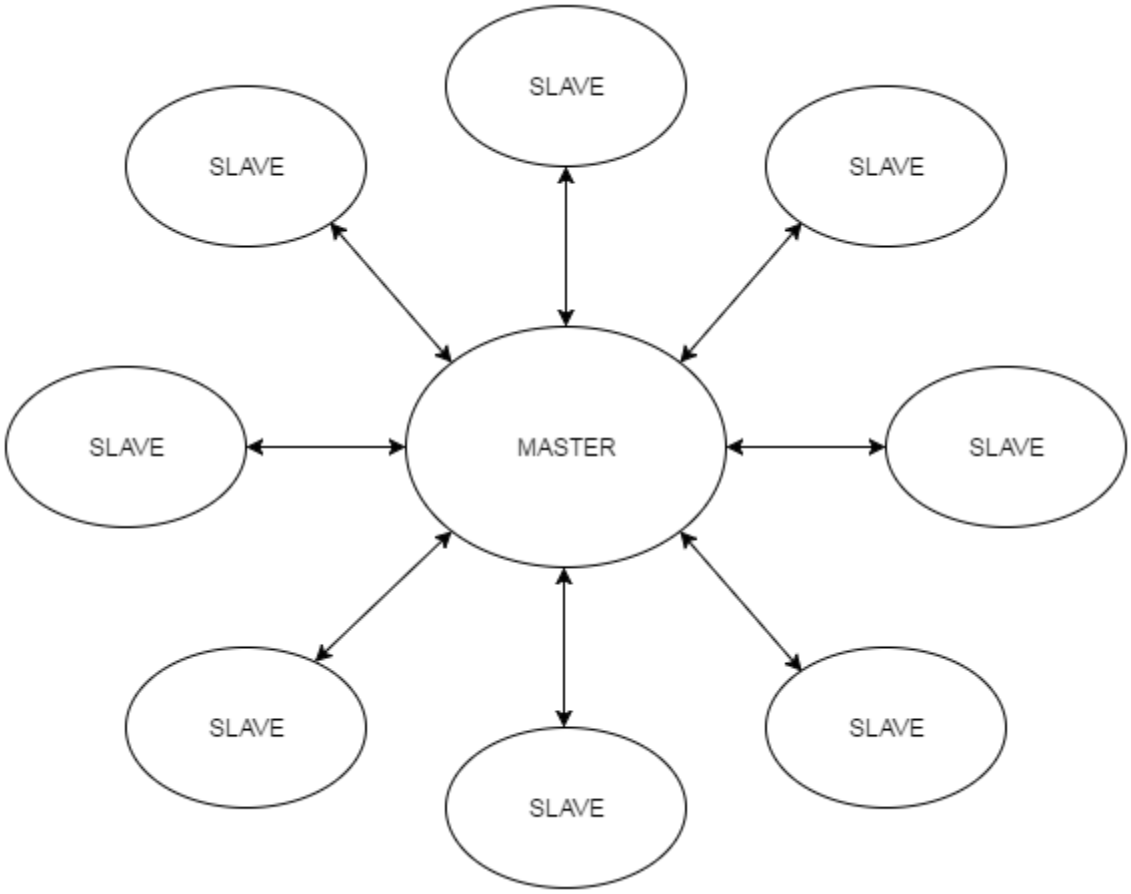

Przykładowe wyniki

xd	ad
fyć	być
miud	miód
kułka	bułka
wziąść	wziąć
wzglond	wzgląd
otfieracz	otwieracz
kąputerowy	komputerowy
wyrafnowany	wyrafinowany
metodologjia	metodologia
sgffihrgyuuiu	sapfirynie
nieposkromoiny	nieposkromiony
wykwaliifkowaną	wykwalifikowaną

Czasy wykonania

Uwaga, jako że w trakcie wykonywania pomiarów komputery w pracowniach wykonywały również inne zadania, wyniki mogą być lekko przekłamane

Implementacja sekwencyjna vs rozproszona

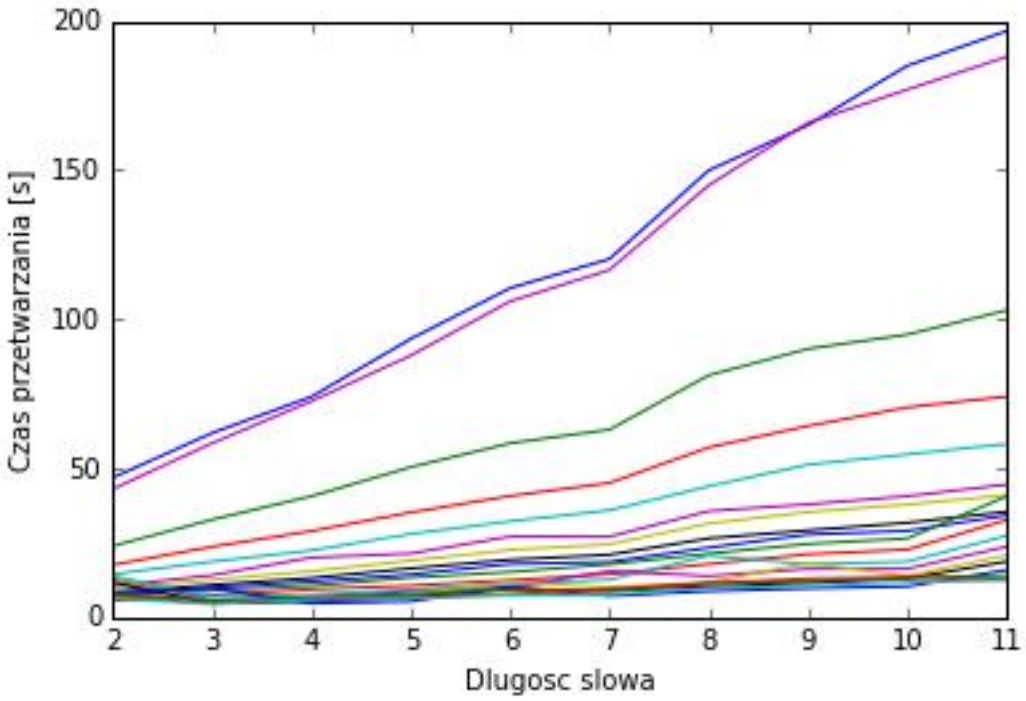

Linia niebieska to algorytm sekwencyjny. Fioletowa – rozproszony z jednym procesem master i jednym slave.
Zgodnie z oczekiwaniami wersja sekwencyjna oraz 1+1 dają praktycznie identyczne wyniki gdyż w tym przypadku pojedynczy slave zachowuje się jak program sekwencyjny.
Dodawanie kolejnych procesów zmniejsza czas wykonania.

Wpływ ilości procesów na czas przetwarzania

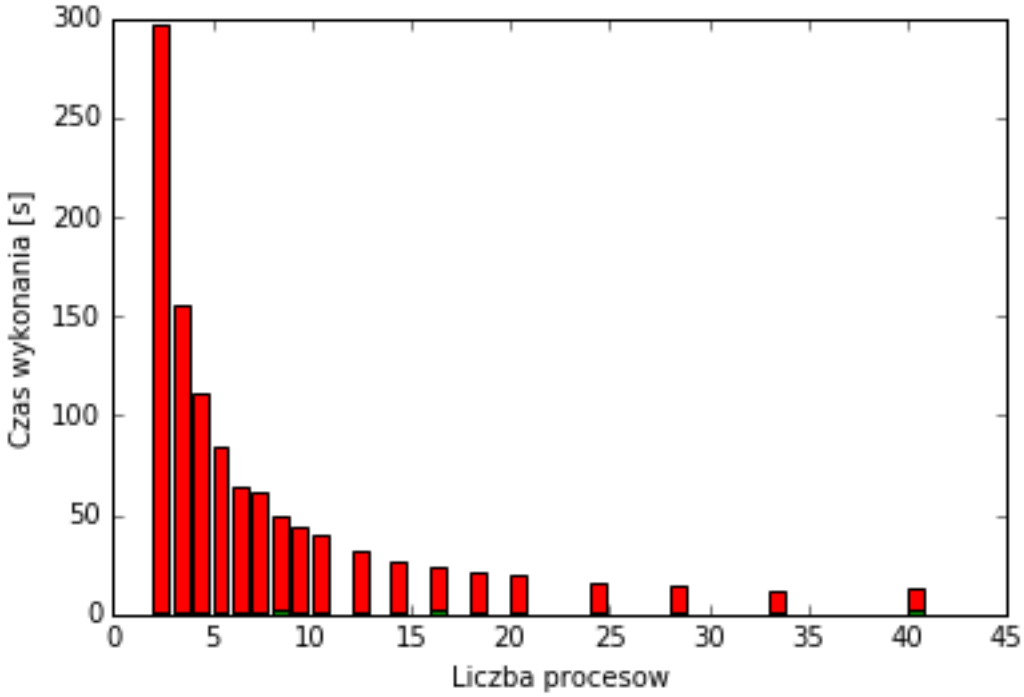

Wraz ze wzrostem liczby procesów spada czas wykonania. Teoretycznie czas powinien być odwrotnie proporcjonalny do liczby procesów (każdy proces ma do wykonania n/p pracy) co znajduje odzwierciedlenie w praktyce.

Czas wykonania w zależności od liczby procesów i długości słowa.

Uwaga, skala jest logarytmiczna!

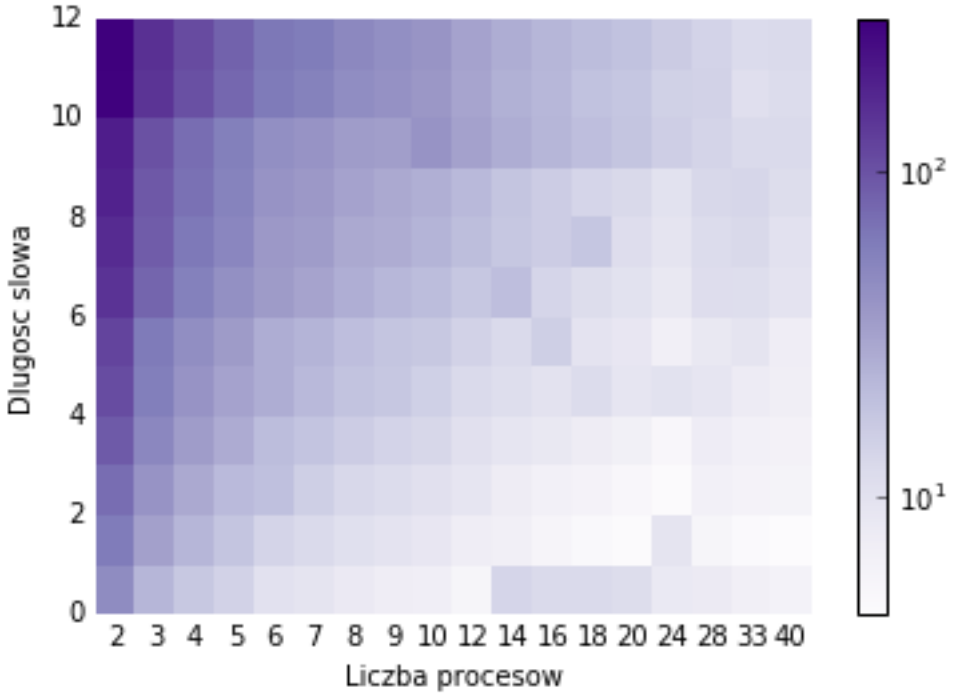

Można zaobserwować, że większy wpływ na czas wykonania ma liczba procesów niż długość słowa.

Czas obliczeń vs czas komunikacji.

Dodatkowo sprawdzono ile czasu zajmuje rozsyłanie słowników w stosunku do obliczeń.
Wykres dla n=12

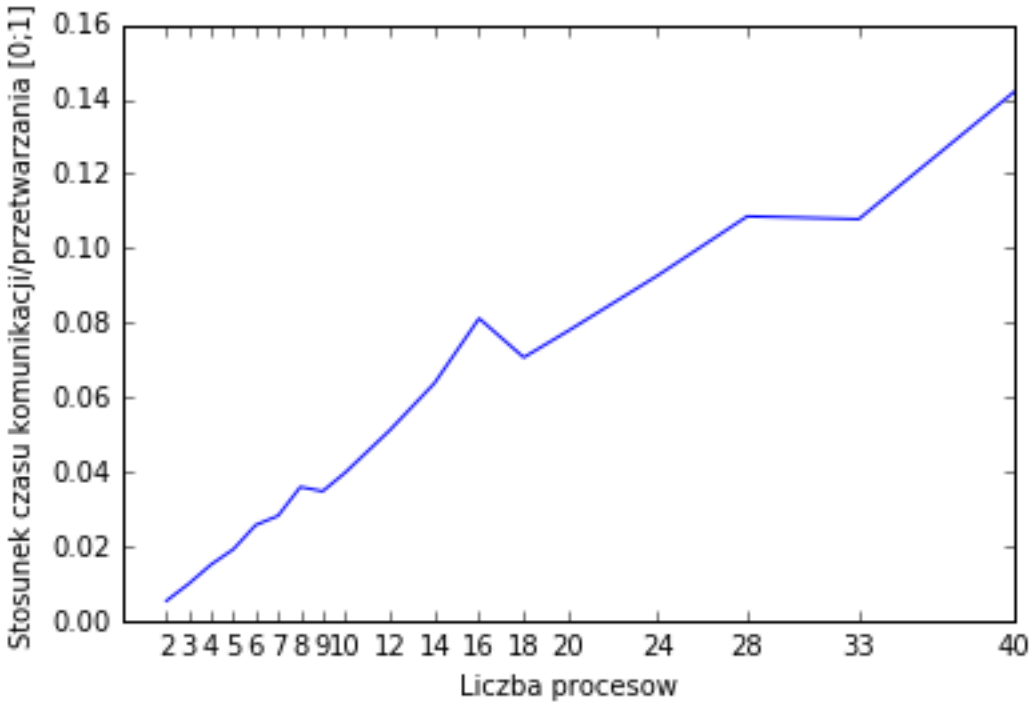

Zaobserwowana zależność jest zgoda z intuicją. Początkowa komunikacja (rozesłanie słowników) ma złożoność n-1 (bo wysyła się słownik do n-1 slave'ów). Późniejsze odbieranie wyników również wymaga n-1 komunikacji, co w sumie daje O(n-1+n-1)=O(2n)=O(n) czyli zależność liniową, widoczną na wykresie.